



CLUSTERING

Master 2 SIAD

Année 2026-2027

OBJECTIFS



A partir de l'étude d'un cas concret, maîtriser la conception d'une typologie, la présentation et les préconisations qui en découlent.



- Prise de recul sur les données
- Interprétation des résultats
- Présentation des résultats
- Préconisations



RAPPELS MÉTHODOLOGIQUES



Prise en main des données et de la problématique

Tri des variables, statistiques descriptives




Analyse factorielle des données brutes

ACP, ACF, ACM



Classification basée sur l'analyse factorielle

CAH, Nuée dynamique ...



Modélisation de la classification

Modèle d'affectation des individus aux classes



ETUDE DE CAS

Problématique

Le service marketing de Karafun souhaite dresser un profil des clients:

- pour améliorer sa connaissance client
- pour adapter ses actions de fidélisation et d'acquisition selon les différents profils d'abonnés

Pour cela vous disposez d'un fichier contenant la liste des clients avec leurs caractéristiques



DONNÉES DISPONIBLES

Variable	Signification
id_anonyme	Identifiant anonymisé de l'abonné
anciennete_client_tr	Ancienneté depuis le tout premier abonnement souscrit (en mois, tranches)
anciennete_abonnement_tr	Ancienneté du cycle d'abonnement en cours (en mois, tranches)
statut_abonnement	Abonnement actif ou non actif à la date de référence
type_client	Statut de fidélité : nouveau / retained / reactivated / churn
type_very_first_abo	Nature du tout premier abonnement souscrit : payant / réduit / offert
type_first_abo_last_streak	Nature du premier abonnement du cycle en cours : payant / réduit / offert
ratio_fidelite_tr	Part des mois éligibles où le client a été abonné, depuis son tout premier abonnement (tranches)
methode_paiement	Moyen de paiement utilisé (Stripe, Apple, Android, Paypal, Amazon...)
nb_abo_periode	Nombre de mois abonnés sur la période d'observation (1 à 12)
valeur_12M_tr	Valeur cumulée générée sur la période (tranches)
avg_sessions_actifs_tr	Nombre moyen de sessions par mois d'abonnement actif (tranches)
avg_songs_sessions_tr	Nombre moyen de chansons jouées par session (tranches)
utilise_remote	A déjà utilisé la fonctionnalité remote (oui/non)
zone_geo	Zone géographique (FR / CA / US / UK / ...)

MÉTHODOLOGIE

Construction de la typologie en 3 étapes

Etape technique permettant de faire une première connaissance des liens entre les variables. Permet d'éliminer des variables gênantes, apporte une base de données idéale pour la classification.

**ANALYSE
FACTORIELLE**

C'est l'étape qui crée la typologie « théorique ». Permet d'identifier les groupes de clients, de choisir le nombre de groupes.

CLASSIFICATION

C'est l'étape qui rend « opérationnelle » la typologie. Elle permet via une segmentation ou une analyse discriminante de donner les règles d'affectation de chaque client à son groupe.

AFFECTATION



A horizontal timeline with four magenta circular markers. Above each marker is a magenta teardrop shape containing a white number (01, 02, 03, 04). Below each marker is a date and a list of tasks. The timeline is decorated with magenta curved lines in the top-left and bottom-right corners.

01

23 SEP

Compréhension de la
problématique
Analyse descriptive du
fichier

02

30 SEP

Réalisation
de l'ACM
et interprétation

03

07 OCT

Réalisation de la CAH et
interprétation des
résultats

04

14 OCT

Modélisation de la
classification
Interprétation des
résultats
Préconisations

LIVRABLES

Présentation



- 1 support visuel à destination de l'équipe marketing
 - objectif
 - présentation des clusters
 - préconisations
- Le support doit être vulgarisé, c'est à dire qu'il va droit au but, qu'il est clair et efficace. Vous pouvez utiliser les zones de commentaires pour préciser vos idées.

Un rapport avec

- une partie portant sur votre étude, et l'interprétation des résultats
- une partie technique, avec le détails de vos stats, les explications des décisions que vous avez prises.
L'objectif est de prévoir qu'une autre personne peut reprendre votre travail des mois plus tard et comprendre votre raisonnement

Rapport



Nom des documents sous la forme : **Gx_By_NOM1_NOM2_prezOUrapport** avec les noms par ordre alphabétique, x numéro du groupe, y le numéro du binôme à envoyer à maureen.dhondt@hotmail.fr



PARTIE 1

Compréhension de la problématique

Analyse descriptive de la base de données

RECUEIL DU BESOIN




Partie la plus importante de l'étude

Si on ne cerne pas le besoin correctement, on n'y répondra pas

TOUJOURS avoir en tête la problématique

On demande quels seront les usages du clustering pour orienter l'étude et cadrer le besoin

Cela permet de faire le tri a priori des données intéressantes dans la construction du modèle



ANALYSE DESCRIPTIVE

Analyse à une dimension


Permet de prendre connaissance de la base, des modalités des variables
Si on ne comprend pas une variable/ une modalité, on demande au métier de l'expliquer

Analyse à deux dimensions


Croisements pertinents des variables entre elles pour répondre à l'objectif de l'étude. Cette étape permet de préparer le clustering et de regrouper des modalités de variables si nécessaire.



CONCLUSION D'ANALYSE



Sur la base de vos analyses

- Réflexion sur les premières intuitions
 - toutes les variables sont elles utiles ?
 - y a t il déjà un groupe identifié de clients qui se ressemblent ?
 - y a t il des biais dans la construction de la table ?
- 



PARTIE 2

Analyse des Correspondances Multiples


L'ACM



Choix des variables

En se basant sur l'étape 1 on choisit les variables que l'on souhaite faire rentrer dans la construction du modèle et on s'assure d'avoir éliminer les modalités rares

Réalisation de l'ACM : proc corresp sous SAS

- Choix du nombre d'axes à retenir + description des 4 premiers
 - Analyse des dimensions retenues
- 

ACM : QUESTIONS PRATIQUES

Histogramme des valeurs propres : Combien de dimensions je retiens ?

- Soit un nombre communément admis (ex : 10 aces)
- Soit le nombre d'axes qui restitue 50% de l'inertie totale
- Soit le nombre d'axes dont l'information restituée est > à l'information moyenne de chaque axe ($1/\text{nb VP}$)

Inertia and Chi-Square Decomposition

Singular Value	Principal Inertia	Chi-Square	Percent	Cumulative Percent	3	6	9	12	15
0.75697	0.57300	51570	13.22	13.22	*****				
0.50438	0.25440	22896	5.87	19.09	*****				
0.46513	0.21635	19471	4.99	24.09	*****				
0.41036	0.16839	15155	3.89	27.97	*****				
0.39894	0.15915	14324	3.67	31.65	*****				
0.38317	0.14682	13214	3.39	35.03	*****				
0.36869	0.13593	12234	3.14	38.17	*****				
0.35426	0.12550	11295	2.90	41.07	*****				
0.35169	0.12368	11131	2.85	43.92	*****				
0.34792	0.12105	10895	2.79	46.71	*****				
0.34184	0.11685	10517	2.70	49.41	*****				
0.34057	0.11599	10439	2.68	52.09	*****				
0.33783	0.11413	10272	2.63	54.72	*****				
0.33458	0.11195	10075	2.58	57.30	*****				
0.33417	0.11167	10050	2.58	59.88	*****				
0.33306	0.11093	9984	2.56	62.44	*****				
0.33177	0.11007	9907	2.54	64.98	*****				
0.33079	0.10942	9848	2.53	67.51	*****				
0.32992	0.10885	9796	2.51	70.02	*****				
0.32843	0.10787	9708	2.49	72.51	*****				
0.32487	0.10554	9499	2.44	74.94	*****				
0.32313	0.10441	9397	2.41	77.35	*****				
0.31747	0.10079	9071	2.33	79.68	*****				
0.31614	0.09994	8995	2.31	81.99	*****				
0.31129	0.09690	8721	2.24	84.22	*****				
0.30077	0.09047	8142	2.09	86.31	***				
0.29136	0.08489	7640	1.96	88.27	***				
0.28868	0.08333	7500	1.92	90.19	***				
0.28613	0.08187	7368	1.89	92.08	***				
0.26760	0.07161	6445	1.65	93.73	***				
0.25761	0.06636	5973	1.53	95.26	***				
0.24837	0.06169	5552	1.42	96.69	**				
0.23662	0.05599	5039	1.29	97.98	**				
0.22159	0.04910	4419	1.13	99.11	**				
0.19605	0.03843	3459	0.89	100.00	*				

$1/35 \times 100 = 2,85$

ACM : QUESTIONS PRATIQUES

Analyse des axes : Quelles modalités sont significatives ?

On retient les modalités dont la contribution est supérieure à la contribution moyenne $(\frac{1}{nb\ total\ modalités})$

Puis on analyse les coordonnées des modalités significatives

Contribution moyenne : 1/62

Seuil0,0161				
Modalité	Dim1	Contr1	Dim2	Contr2
methode_paiement__Apple	-0,138	0,0016	0,06	0,0005
methode_paiement__Paypal	0,31	0,0027	0,14	0,0009
type_client__reactivated	0,052	0,0001	-1,137	0,0762
valeur_12M__moins_10	-0,788	0,0453	0,932	0,0994
valeur_12M__90_et_plus	1,631	0,0628	0,007	0
utilise_remote__oui	-0,161	0,0016	-0,481	0,0228
zone_geo__US	0,197	0,0041	0,196	0,0006



PARTIE 3

Classification

MÉTHODES DE CLASSIFICATION

Classification	Avantage	Inconvénient
non hierarichique (Ex : nuée dynamiques, centres mobiles ...)	Rapide donc classification sur une BDD volumineuse	Nombre de classes imposé dès le départ
Hiérarchique (ex : CAH)	Choix du nombre optimal de classes	Temps de traitement long

Classification mixte pour combiner les avantages des 2 méthodes

CAH: choix du nb de classes (proc cluster, dendrogramme, CCC, R2 semi-partiel)

Nuées dynamiques (proc fastclus)


MÉTHODES DE CLASSIFICATION

Quelle que soit la méthode retenue, réalisation de statistiques descriptives pour décrire le contenu de chaque groupe issu de la classification


CAH : QUESTIONS PRATIQUES

Comment déterminer le nombre de classes optimal ?

Méthode intuitive
découpage du dendrogramme




Indicateurs de mesure de qualité



R2 semi-partiel: (SPRSQ): mesure la perte d'inertie interclasse provoquée en regroupant 2 classes

Cubic clustering criterion (CCC):
si >2 alors la classification est bonne





PARTIE 4

Affectation

AFFECTATION DE LA CLASSIFICATION



Un clustering se construit une fois

Une mise à jour est nécessaire pour attribuer un cluster aux nouveaux clients, mais aussi car le comportement du client a pu changer.

On peut attribuer un cluster à un client de plusieurs manières

- règles d'attribution simples
 - modélisation (pour le TD méthode retenue, avec une régression logistique généralisée)
- 